

Attention Mechanism

Query, Key, Value를 직관 - 수식 - 사례로 연결하는 학습 노트

핵심 문장

Q와 K는 누구를 참고할지 정하는 주소 체계이고, V는 실제로 가져와 합성할 정보다. Q, K, V는 입력에 원래 존재하는 세 종류의 데이터가 아니라, 학습되는 서로 다른 선형 투영(projection)이다.

1. 먼저 버려야 할 오해

오해	교정
Q는 질문, K는 열쇠, V는 정답이다.	비유일 뿐이다. 실제로는 모두 같은 토큰 표현에서 서로 다른 행렬로 만든 벡터다.
K에는 토큰의 의미가, V에는 값이 들어 있다.	K는 Q와의 매칭에 유리하도록, V는 다음 레이어에 전달하기 유리하도록 학습된다.
하나의 attention head가 하나의 명시적 문법 규칙을 담당한다.	그런 보장은 없다. 특정 관계를 잘 포착하는 head가 관찰될 수는 있지만, 기능은 분산되고 총마다 바뀐다.

2. 수식: 같은 입력에서 세 관점을 만든다

문장 속 i번째 토큰의 현재 표현을 x 라고 하면, 한 attention head는 다음을 계산한다.

$$q = xW_Q \quad k = xW_K \quad v = xW_V$$

W_Q, W_K, W_V 는 훈련으로 학습되는 서로 다른 가중치 행렬이다. 입력 x 는 하나지만, 모델은 목적이 다른 세 벡터를 만든다. self-attention에서는 각 토큰이 Q, K, V를 모두 가진다.

3. 구체적 사례: ‘그는’이 누구를 가리키는가

문장: ‘철수가 영희에게 책을 주었고, 그는 웃었다.’

목표: ‘그는’ 토큰의 새 표현을 만들 때, 앞 문맥의 어느 토큰을 얼마나 참고할지 정한다.

① ‘그는’은 자신의 Query $q_{\text{그는}}$ 를 만든다. 학습이 잘 됐다면 이 방향은 ‘앞 문맥에서 남성 단수 인물 후보를 찾아라’ 같은 패턴에 반응할 수 있다. 이것은 사람이 코딩한 규칙이 아니라 데이터와 역전파가 만든 표현이다.

② '그는'의 Query를 모든 토큰의 Key와 내적한다.

$$s = q_{\text{그는}} \cdot k$$

후보 토큰	Q-K 점수	해석
철수	8.0	'그는'의 Query와 가장 잘 맞는 Key
영희	2.1	인물이지만 이 문맥에서는 덜 일치
책	-0.5	사물 - 관련도 낮음
주었고	0.7	동사 - 일부 문맥 관계만 있음

③ softmax가 점수를 가중치로 바꾼다. 예를 들어 철수 0.94, 영희 0.06, 나머지는 거의 0이 될 수 있다.

$$a = \text{softmax}(s / \sqrt{d_k})$$

④ 마지막으로 이 가중치로 Value를 합성한다. 여기서 실제로 다음 표현으로 운반되는 것은 K가 아니라 V다.

$$z_{\text{그는}} = \sum a v$$

결론: '그는'의 새 표현 $z_{\text{그는}}$ 는 철수의 Value를 주로 섞어 받는다. 그래서 이후 레이어는 '그는'을 문장 속 철수와 연결된 표현으로 처리할 가능성이 높아진다.

4. 왜 Q, K, V를 굳이 분리하는가

구성	분리하지 않으면	분리의 이점
Q와 K	'무엇을 찾는가'와 '내가 무엇으로 검색되는가'가 같은 좌표계에 묶인다.	찾는 기준과 검색 표식을 독립적으로 최적화한다. 비대칭 관계를 표현할 수 있다.
K와 V	매칭에 좋은 특징만 전달해야 한다.	검색을 위한 압축 표식(K)과, 전달할 풍부한 문맥 정보(V)를 다르게 학습한다.

5. 검색 엔진 비유 - 도움이 되지만 완전하지는 않다

Attention	검색 엔진 비유
Query	사용자가 입력한 검색어
Key	문서의 검색 색인
attention weight	검색 결과별 관련도
Value	가져와 요약할 문서 내용

차이점도 중요하다. 일반 검색 엔진의 색인은 사람이 설계할 수 있지만, Transformer의 Q/K/V 좌표계는 end-to-end 학습으로 만들어진다. 그래서 모델 내부 벡터의 개별 축에 사람이 읽을 수 있는 고정된 의미가 있다고 가정하면 안 된다.

6. $\sqrt{d_k}$ 로 나누는 이유

Q와 K의 차원이 커질수록 내적의 크기와 분산도 커진다. 이를 그대로 softmax에 넣으면 가장 큰 점수 하나가 지나치게 지배해 기울기가 작아지고 학습이 불안정해질 수 있다. 따라서 scaled dot-product attention은 다음처럼 나눈다.

$$\text{Attention}(Q, K, V) = \text{softmax}(QK / \sqrt{d_k})V$$

이 식에서 QK는 ‘누구를 참고할지’, softmax는 ‘얼마나 참고할지’, 마지막 V 곱은 ‘무슨 정보를 가져올지’를 담당한다.

7. 이해 점검 문제

- 1) Value를 Key와 똑같이 두면 모델의 표현력에서 무엇을 잃는가?
- 2) ‘그는’의 Query가 ‘철수’의 Key에 큰 내적을 낸다는 말은, 철수와 그의 임베딩이 단순히 유사하다는 말과 어떻게 다른가?
- 3) attention weight가 0.94인 철수의 Key가 아니라 Value가 최종 합성에 쓰이는 이유는 무엇인가?
- 4) 한 head가 대명사 관계를 포착했다고 해서 모델이 문법 규칙을 명시적으로 이해한다고 결론 내려도 되는가? 왜 아닌가?

한 줄 결론

Query로 무엇을 찾을지 정하고, Key로 관련 대상을 고르고, Value에서 정보를 가져온다. 다만 이 세 역할은 사람이 부여한 뜻이 아니라 학습을 통해 형성되는 계산상의 역할이다.